Co-krigeage séquentiel : compléments mathématiques

Dictionnaire des notations de Le Gratiet & Cannamela et démonstrations détaillées

Complément de `sequential_cokriging.tex` (même dossier) · 20/10/2026

Ce document justifie pas à pas les résultats de la note d'implémentation. « (Nk) » désigne l'équation k de la note, « LG (k) » l'équation k de Le Gratiet & Cannamela [1]. Tous les hyperparamètres (longueurs de corrélation, variances, bruits) sont supposés fixés, comme dans [1] pendant une itération. Les identités matricielles utilisées ont été vérifiées numériquement.

1 Dictionnaire des notations

Note	Le Gratiet & Cannamela	Sens, et objet mfego
L	s	nombre de niveaux (`model.num_levels`)
$Z_l(\boldsymbol{x})$; $\mathcal{D}_l$, n_l ; $\boldsymbol{z}_l$	$Y^l(\boldsymbol{x})$; $\mathbf{D}^l$, n_l ; $\mathbf{y}^l = y^l(\mathbf{D}^l)$	processus du code l ; plan du niveau l ; valeurs calculées (`data.get_training_data(l)`)
δ_l	δ^l	correction (« biais ») apportée par le niveau l (GP `model.gps[l-1]`)
m_l (constante)	$\mathbf{f}_l'(\boldsymbol{x})\beta_l$	tendance de δ^l (`gp.y_mean`)
$k_l(\boldsymbol{x},\boldsymbol{x}')$	$\sigma_l^2\, r_l(\boldsymbol{x},\boldsymbol{x}')$	covariance a priori de δ^l ; mfego : `y_std**2 * (t1*r + t2)`
$\theta_{l,m}$	θ_l^m	longueurs de corrélation (`gp.kernel.lengthscale`, cube unité)
ρ_{l-1} (ponctuel)	ρ_{l-1}, de moyenne a posteriori $\hat\rho_{l-1}$	facteur d'échelle entre $l-1$ et l (`model.rhos[l-2]`)
ρ_{l-1}^2	$\hat\sigma^2_{\rho_{l-1}} = \mathbb{E}[\rho_{l-1}^2]$	poids de propagation d'un niveau au suivant
$P_j^2 = \prod_{k=j}^{L-1}\rho_k^2$	$\prod_{k=j}^{s-1}\hat\sigma^2_{\rho_k}$	gain de la correction j jusqu'à la sortie HF (`level_weights(model)**2`)
$\boldsymbol{d}_l$	$\mathbf{y}^l - \rho_{l-1}\, y^{l-1}(\mathbf{D}^l)$	résidus observés du niveau l (`gp.y_train`)
$\sigma_l^2(\boldsymbol{x}) = k_l^n(\boldsymbol{x},\boldsymbol{x})$	$\sigma^2_{\delta^l}(\boldsymbol{x})$	variance a posteriori de la correction l au point $\boldsymbol{x}$
$\mathbb{E}[Z_l(\boldsymbol{x})\|\boldsymbol{z}]$, $\mathrm{Var}[Z_l(\boldsymbol{x})\|\boldsymbol{z}]$	$\mu^l_{n_l}(\boldsymbol{x})$, $k^l_{n_l}(\boldsymbol{x},\boldsymbol{x})$	moyenne et variance prédictives du niveau l (`model.predict_batch(x, level=l)`)
$e_l(\boldsymbol{x}_i)$, $s_l^2(\boldsymbol{x}_i)$	$\varepsilon_{\text{LOO-CV},l}(\boldsymbol{x}_i^l)$, $\sigma^2_{\text{LOO-CV},l}(\boldsymbol{x}_i^l)$	erreur et variance LOO (`model.leave_one_out(l, by_location=True)`)
c_l, c_l/c_{l-1}	t_l, $B_{l/l-1}$	coût d'un calcul (`data.costs`)
$G_l(\boldsymbol{x}_0)$	$\approx \big(\prod_{k=l}^{s-1}\hat\sigma^2_{\rho_k}\big)\,\mathrm{IMSE}^l_{\text{red}}(\boldsymbol{x}_0)$	réduction de l'IMSE *haute fidélité* (§ 6)

À retenir — les quatre « variances » de Le Gratiet & Cannamela

1. σ_l^2 **(un nombre)** est le paramètre d'amplitude du processus δ^l : a priori, $\mathrm{Var}[\delta^l(\boldsymbol{x})] = \sigma_l^2$ puisque $r_l(\boldsymbol{x},\boldsymbol{x}) = 1$. C'est l'écart-type typique de la correction, au carré. Il est estimé par maximum de vraisemblance restreint : c'est le premier « LG (4) », l'article a deux équations (4).
2. $\sigma^2_{\delta^l}(\boldsymbol{x})$ **(une fonction de $\boldsymbol{x}$)** est la variance *a posteriori* de la correction l en $\boldsymbol{x}$, une fois vues les données. LG la définissent au § 3.1 par la matrice bordée de LG (3). Avec $\mathbf{u} = \mathbf{h}_l(\boldsymbol{x}) - \mathbf{H}_l'\mathbf{R}_l^{-1}\mathbf{r}_l(\boldsymbol{x})$, elle vaut
$$\sigma^2_{\delta^l}(\boldsymbol{x}) = \sigma_l^2\Big(\underbrace{1}_{\text{a priori}} \underbrace{-\,\mathbf{r}_l'\mathbf{R}_l^{-1}\mathbf{r}_l}_{\text{apport des données}} \underbrace{+\,\mathbf{u}'(\mathbf{H}_l'\mathbf{R}_l^{-1}\mathbf{H}_l)^{-1}\mathbf{u}}_{\text{incertitude sur }(\rho_{l-1},\beta_l)}\Big), \qquad \mathbf{h}_l(\boldsymbol{x}) = \big(\mu^{l-1}_{n_{l-1}}(\boldsymbol{x}),\ \mathbf{f}_l(\boldsymbol{x})\big).$$
   Notre $\sigma_l^2(\boldsymbol{x})$ est la même quantité *sans le dernier terme*, puisque ρ et la tendance sont fixés. Pour $l=1$, $\sigma^2_{\delta^1}(\boldsymbol{x}) = k^1_{n_1}(\boldsymbol{x},\boldsymbol{x})$.
3. $\hat\sigma^2_{\rho_{l-1}}$ **(un nombre sans rapport avec la sortie)** est le moment d'ordre 2 de ρ_{l-1} a posteriori : $\mathbb{E}[\rho^2] = \hat\rho^2 + \mathrm{Var}(\rho)$. C'est un *gain au carré*, pas une variance de sortie (§ 3.4). À σ_l^2 connu, la loi a posteriori de (ρ_{l-1},β_l) est gaussienne de covariance $\sigma_l^2(\mathbf{H}_l'\mathbf{R}_l^{-1}\mathbf{H}_l)^{-1}$ (moindres carrés généralisés) ; l'article imprime $[(\mathbf{H}'\mathbf{R}^{-1}\mathbf{H})^{-1}]_{1,1}$ sans le facteur σ_l^2. Si ρ est connu, $\hat\sigma^2_\rho = \rho^2$.
4. $k^l_{n_l}(\boldsymbol{x},\tilde{\boldsymbol{x}})$ est la covariance prédictive du co-krigeage au niveau l, conditionné à toutes les données des niveaux $1..l$ (l'indice n_l le rappelle). $k^l_{n_l}(\boldsymbol{x},\boldsymbol{x})$ est la variance prédictive, ou MSE, du niveau l. Sa relation avec les précédentes est LG (4) :
$$k^l_{n_l}(\boldsymbol{x},\boldsymbol{x}) = \sum_{j=1}^{l}\sigma^2_{\delta^j}(\boldsymbol{x})\prod_{k=j}^{l-1}\hat\sigma^2_{\rho_k}.$$
   k est le *total*, les $\sigma^2_{\delta^j}(\boldsymbol{x})$ en sont les *morceaux*, et les $\hat\sigma^2_\rho$ les gains qui les propagent.

2 De (N1) à $Z_L = \sum_j P_j\,\delta_j$

On part de (N1) : $Z_1 = \delta_1$ et $Z_l(\boldsymbol{x}) = \rho_{l-1} Z_{l-1}(\boldsymbol{x}) + \delta_l(\boldsymbol{x})$ pour $l \geq 2$, avec des ρ constants. On *déroule* la récurrence :

$$Z_2 = \rho_1\delta_1 + \delta_2, \qquad Z_3 = \rho_2 Z_2 + \delta_3 = \rho_2\rho_1\,\delta_1 + \rho_2\,\delta_2 + \delta_3.$$

Énoncé. Pour tout l, $Z_l = \sum_{j=1}^{l} P_{j\to l}\,\delta_j$ avec $P_{j\to l} = \prod_{k=j}^{l-1}\rho_k$, et la convention $P_{l\to l} = 1$ (produit vide).

Récurrence. L'énoncé est vrai pour $l = 1$. S'il l'est au rang $l-1$, alors

$$Z_l = \rho_{l-1}\sum_{j=1}^{l-1} P_{j\to l-1}\,\delta_j + \delta_l = \sum_{j=1}^{l-1}\Big(\rho_{l-1}\prod_{k=j}^{l-2}\rho_k\Big)\delta_j + \delta_l = \sum_{j=1}^{l-1} P_{j\to l}\,\delta_j + P_{l\to l}\,\delta_l. \qquad \square$$

Pour $l = L$, on note $P_j = P_{j\to L}$. C'est une identité entre *processus aléatoires*, vraie en chaque $\boldsymbol{x}$ et avant toute observation. Physiquement, la correction δ_j traverse les niveaux $j+1,\dots,L$ et elle est multipliée par ρ à chaque traversée ; P_j est le gain total de cette chaîne. (Avec un $\rho(\boldsymbol{x})$, on aurait simplement $P_j(\boldsymbol{x}) = \prod_k \rho_k(\boldsymbol{x})$.)

3 De $Z_L = \sum_j P_j\delta_j$ à l'espérance et à la variance (N2)

3.1 Ce que donne l'algèbre seule

Par linéarité de l'espérance conditionnelle, $\mathbb{E}[Z_L(\boldsymbol{x})|\boldsymbol{z}] = \sum_j P_j\,\mathbb{E}[\delta_j(\boldsymbol{x})|\boldsymbol{z}]$. Pour la variance d'une combinaison linéaire,

$$\mathrm{Var}[Z_L(\boldsymbol{x})|\boldsymbol{z}] = \sum_j P_j^2\,\mathrm{Var}[\delta_j(\boldsymbol{x})|\boldsymbol{z}] + 2\sum_{j<k} P_jP_k\,\mathrm{Cov}[\delta_j(\boldsymbol{x}),\delta_k(\boldsymbol{x})|\boldsymbol{z}]. \tag{1}$$

Pour obtenir (N2), il faut deux choses : que les covariances croisées *a posteriori* soient nulles, et que $\mathbb{E}[\delta_j|\boldsymbol{z}]$ et $\mathrm{Var}[\delta_j|\boldsymbol{z}]$ ne dépendent que des données du niveau j.

3.2 L'indépendance a priori ne suffit pas

Prenons deux corrections indépendantes $\delta_1,\delta_2 \sim \mathcal{N}(0,1)$ en un point, $\rho = 1$, et observons *seulement* $z_2 = \delta_1 + \delta_2$. Le conditionnement gaussien donne $\mathrm{Cov}[\delta_1,\delta_2|z_2] = 0 - \frac{1\cdot1}{2} = -\frac{1}{2}$. Savoir que la somme vaut z_2 couple les deux termes : si l'un est grand, l'autre est petit. Le terme croisé de (1) vaut alors -1, et il compense exactement $\mathrm{Var}[\delta_1|z_2] + \mathrm{Var}[\delta_2|z_2] = \frac{1}{2} + \frac{1}{2}$: la variance totale est nulle, ce qui est correct puisque Z_2 est observé. Sans terme croisé, on obtiendrait 1, ce qui est faux.

3.3 L'imbrication rétablit l'indépendance

Si $\mathcal{D}_j \subset \mathcal{D}_{j-1}$, la valeur z_{j-1} est connue en chaque point de $\mathcal{D}_j$. On définit les résidus

$$\boldsymbol{d}_1 = \boldsymbol{z}_1, \qquad \boldsymbol{d}_j = \boldsymbol{z}_j - \rho_{j-1}\,\boldsymbol{z}_{j-1}(\mathcal{D}_j) \quad (j \geq 2).$$

— ***d* et *z* contiennent la même information.** On repasse de $\boldsymbol{d}$ à $\boldsymbol{z}$ par $\boldsymbol{z}_j = \boldsymbol{d}_j + \rho_{j-1}\boldsymbol{z}_{j-1}(\mathcal{D}_j)$, de proche en proche. L'application $\boldsymbol{z} \mapsto \boldsymbol{d}$ est linéaire et triangulaire par blocs, avec des identités sur la diagonale ; son déterminant vaut 1, elle est inversible. Conditionner par $\boldsymbol{z}$ ou par $\boldsymbol{d}$, c'est donc la même chose.

— **$\boldsymbol{d}_j$ ne dépend que de δ_j.** Sans bruit, $\boldsymbol{d}_j = Z_j(\mathcal{D}_j) - \rho_{j-1}Z_{j-1}(\mathcal{D}_j) = \delta_j(\mathcal{D}_j)$ d'après (N1).

— **La loi a posteriori se factorise.** Les δ_j sont indépendants a priori, et chaque $\boldsymbol{d}_j$ n'est lié qu'à δ_j. Par la formule de Bayes,

$$p(\delta_1,\dots,\delta_L \mid \boldsymbol{d}_1,\dots,\boldsymbol{d}_L) \;\propto\; \prod_{j=1}^{L} p(\delta_j)\,p(\boldsymbol{d}_j \mid \delta_j) \;\propto\; \prod_{j=1}^{L} p(\delta_j \mid \boldsymbol{d}_j).$$

Les δ_j restent donc indépendants a posteriori, et chacun ne « voit » que ses propres résidus. Par conséquent, $\mathrm{Cov}[\delta_j,\delta_k|\boldsymbol{z}] = 0$ pour $j \neq k$, $\mathbb{E}[\delta_j(\boldsymbol{x})|\boldsymbol{z}] = \mu_j(\boldsymbol{x})$ et $\mathrm{Var}[\delta_j(\boldsymbol{x})|\boldsymbol{z}] = \sigma_j^2(\boldsymbol{x})$, où μ_j et σ_j^2 sont les formules du krigeage simple d'un *seul* GP sur $\boldsymbol{d}_j$:

$$\mu_j(\boldsymbol{x}) = m_j + \mathbf{k}_j(\boldsymbol{x})^{\mathsf{T}}\widetilde{\boldsymbol{K}}_j^{-1}(\boldsymbol{d}_j - m_j), \qquad \sigma_j^2(\boldsymbol{x}) = k_j(\boldsymbol{x},\boldsymbol{x}) - \mathbf{k}_j(\boldsymbol{x})^{\mathsf{T}}\widetilde{\boldsymbol{K}}_j^{-1}\mathbf{k}_j(\boldsymbol{x}), \qquad \widetilde{\boldsymbol{K}}_j = \mathbf{K}_j + \tau_j^2\mathbf{I}.$$

En reportant dans (1), on obtient (N2) : $\mathbb{E}[Z_L|\boldsymbol{z}] = \sum_j P_j\mu_j$ et $\mathrm{Var}[Z_L|\boldsymbol{z}] = \sum_j P_j^2\sigma_j^2$. Le même argument donne la covariance, $\sum_j P_j^2 k_j^n(\boldsymbol{x},\boldsymbol{x}')$.

Avec du bruit. On a alors $\boldsymbol{d}_j = \delta_j(\mathcal{D}_j) + \varepsilon_j - \rho_{j-1}\varepsilon_{j-1}(\mathcal{D}_j)$: $\boldsymbol{d}_j$ et $\boldsymbol{d}_{j-1}$ partagent le bruit ε_{j-1}. La factorisation n'est plus qu'approchée, à l'ordre $\rho^2\tau_{j-1}^2/\sigma_j^2$; c'est l'écart de 10^{-4} mesuré dans la note.

3.4 Le même résultat dans les notations de LG

LG (1) place le conditionnement dans le modèle lui-même : $Y^l = \rho_{l-1}\tilde{Y}^{l-1} + \delta^l$, où $\tilde{Y}^{l-1}$ est *déjà* le niveau $l-1$ conditionné à ses données. C'est la formulation récursive de [2], équivalente à celle de Kennedy & O'Hagan sur plan imbriqué [3, prop. 3.1]. On prend LG (3) en $\tilde{\boldsymbol{x}} = \boldsymbol{x}$; le second terme est $\sigma^2_{\delta^l}(\boldsymbol{x})$ par définition (§ 3.1 de l'article), d'où

$$k^l_{n_l}(\boldsymbol{x},\boldsymbol{x}) = \hat{\sigma}^2_{\rho_{l-1}}\, k^{l-1}_{n_{l-1}}(\boldsymbol{x},\boldsymbol{x}) + \sigma^2_{\delta^l}(\boldsymbol{x}).$$

On déroule cette récurrence exactement comme au § 2, et on obtient LG (4).

Pourquoi un moment d'ordre 2 pour ρ. Chez LG, ρ est aléatoire, indépendant de $\tilde{Y}^{l-1}$. Pour un produit de deux variables indépendantes, la loi de la variance totale donne

$$\mathrm{Var}(\rho\,\tilde{Y}) = \underbrace{\mathbb{E}[\rho^2]}_{\hat{\sigma}^2_\rho}\mathrm{Var}(\tilde{Y}) + \mathrm{Var}(\rho)\,\big(\mathbb{E}\tilde{Y}\big)^2.$$

Le premier terme donne $\hat{\sigma}^2_\rho\, k^{l-1}$. Le second est rangé dans le terme $\mathbf{u}$ de $\sigma^2_{\delta^l}(\boldsymbol{x})$, car $\mathbf{h}_l$ contient $\mu^{l-1}(\boldsymbol{x}) = \mathbb{E}\tilde{Y}$. Avec ρ fixé (mfego), $\mathrm{Var}(\rho) = 0$: $\hat{\sigma}^2_\rho \to \rho^2$ et $\sigma^2_{\delta^l}(\boldsymbol{x}) \to \sigma^2_l(\boldsymbol{x})$, ce qui redonne (N2).

4 La proposition 2 en détail

4.1 LOO d'un seul GP (Dubrule)

Soit $\boldsymbol{w} = \boldsymbol{d}_j - m_j$ les résidus centrés : $\boldsymbol{w} \sim \mathcal{N}(0, \widetilde{\boldsymbol{K}})$. On note $\boldsymbol{\Lambda} = \widetilde{\boldsymbol{K}}^{-1}$ (la matrice de précision) et $\boldsymbol{\alpha} = \boldsymbol{\Lambda}\boldsymbol{w}$. Vue comme fonction de la seule composante w_i, la densité $\propto \exp(-\frac{1}{2}\boldsymbol{w}^\mathsf{T}\boldsymbol{\Lambda}\boldsymbol{w})$ s'écrit $\exp\big(-\frac{1}{2}\Lambda_{ii}w_i^2 - w_i\sum_{k\neq i}\Lambda_{ik}w_k + \dots\big)$. C'est une gaussienne en w_i, de variance $1/\Lambda_{ii}$ et de moyenne $-\frac{1}{\Lambda_{ii}}\sum_{k\neq i}\Lambda_{ik}w_k$. Donc

$$e_i = w_i - \mathbb{E}[w_i|\boldsymbol{w}_{-i}] = \frac{(\boldsymbol{\Lambda}\boldsymbol{w})_i}{\Lambda_{ii}} = \frac{\alpha_i}{\Lambda_{ii}}, \qquad s_i^2 = \frac{1}{\Lambda_{ii}}, \qquad z_i^2 = \frac{\alpha_i^2}{\Lambda_{ii}} \qquad \text{(N3)}.$$

Une seule inversion de $\widetilde{\boldsymbol{K}}$ suffit pour les n prédictions sans le point i. La matrice $\mathbf{K}_l$ de LG, $[\mathbf{R}^{-1}]_{-i,-i} - [\mathbf{R}^{-1}]_{-i,i}[\mathbf{R}^{-1}]_{i,-i}/[\mathbf{R}^{-1}]_{ii}$, n'est autre que $(\mathbf{R}_{-i,-i})^{-1}$: c'est l'inverse de la matrice privée du point i, déduit de l'inverse complet.

4.2 LOO du co-krigeage, niveau par niveau

On fixe $j \geq 2$ et $\boldsymbol{x}_i \in \mathcal{D}_j$. On retire les observations en $\boldsymbol{x}_i$ de *tous* les niveaux (données $\boldsymbol{z}^{(-i)}$). C'est le LOO de LG (« built without the observations $y^1_{i_1}, \dots, y^l_{i_l}$ ») et celui de `leave_one_out(by_location=True)`. Le plan réduit reste imbriqué, donc le § 3 s'y applique, au niveau j comme au niveau L. Avec $Z_j = \rho_{j-1}Z_{j-1} + \delta_j$ et l'indépendance a posteriori :

(A) $\mathbb{E}[Z_j(\boldsymbol{x}_i)|\boldsymbol{z}^{(-i)}] = \rho_{j-1}\,\mathbb{E}[Z_{j-1}(\boldsymbol{x}_i)|\boldsymbol{z}^{(-i)}] + \mathbb{E}[\delta_j(\boldsymbol{x}_i)|\boldsymbol{d}_{j,-i}]$,

(B) $z_j(\boldsymbol{x}_i) = \rho_{j-1}\,z_{j-1}(\boldsymbol{x}_i) + d_j(\boldsymbol{x}_i)$ (définition de d_j ; $\boldsymbol{x}_i \in \mathcal{D}_{j-1}$ par imbrication).

On soustrait (A) de (B). Les erreurs LOO étant « valeur observée moins prédiction »,

$$e_j(\boldsymbol{x}_i) = \rho_{j-1}\,e_{j-1}(\boldsymbol{x}_i) + e_i^{(\delta_j)}, \qquad e_i^{(\delta_j)} = d_j(\boldsymbol{x}_i) - \mathbb{E}[\delta_j(\boldsymbol{x}_i)|\boldsymbol{d}_{j,-i}].$$

Pour les variances, l'indépendance donne $\mathrm{Var}[Z_j(\boldsymbol{x}_i)|\boldsymbol{z}^{(-i)}] = \rho_{j-1}^2\,\mathrm{Var}[Z_{j-1}(\boldsymbol{x}_i)|\boldsymbol{z}^{(-i)}] + \mathrm{Var}[\delta_j(\boldsymbol{x}_i)|\boldsymbol{d}_{j,-i}]$. On ajoute τ_j^2 pour passer à la variance de l'observation, avec $\tau_{j-1} = 0$: $s_j^2 = \rho_{j-1}^2 s_{j-1}^2 + s_i^{2\,(\delta_j)}$. Enfin, $e_i^{(\delta_j)}$ et $s_i^{2\,(\delta_j)}$ sont le LOO du GP δ_j *seul* sur $\boldsymbol{d}_j$, donné par (N3). □

Chez Le Gratiet & Cannamela — traduction terme à terme de LG (6)–(7)

$$\underbrace{\varepsilon_{\mathrm{LOO},l}}_{e_l} = \underbrace{\hat{\rho}_{l-1,i_l}}_{\rho_{l-1}}\,\underbrace{\varepsilon_{\mathrm{LOO},l-1}}_{e_{l-1}} + \underbrace{\frac{\big[\mathbf{R}_l^{-1}(\mathbf{y}^l - \mathbf{H}_l(\hat{\rho};\hat{\beta})_{-i})\big]_{i_l}}{[\mathbf{R}_l^{-1}]_{i_l,i_l}}}_{e_i^{(\delta_l)}=\alpha_i/\Lambda_{ii}}, \qquad \underbrace{\sigma^2_{\mathrm{LOO},l}}_{s_l^2} = \underbrace{\hat{\sigma}^2_{\rho_{l-1,i_l}}}_{\rho^2_{l-1}}\,\underbrace{\sigma^2_{\mathrm{LOO},l-1}}_{s^2_{l-1}} + \underbrace{\frac{\sigma^2_{l,-i_l}}{[\mathbf{R}_l^{-1}]_{i_l,i_l}}}_{s_i^{2(\delta_l)}=1/\Lambda_{ii}} + \underbrace{\varsigma_l}_{0}.$$

— $\mathbf{y}^l - \mathbf{H}_l(\rho;\beta) = \mathbf{y}^l - \rho\,y^{l-1}(\mathbf{D}^l) - \mathbf{F}_l\beta$, ce sont les résidus moins la tendance, donc notre $\boldsymbol{w}$.

— $\boldsymbol{\Lambda} = \mathbf{R}_l^{-1}/\sigma_l^2$: le facteur σ_l^2 se simplifie dans le rapport.

— Chez LG, (ρ, β, σ^2) sont ré-estimés sans le point i, d'où les indices i_l et $-i_l$; ς_l est la part de variance due à cette ré-estimation.

La proposition 2 est donc **LG (6)–(7) à paramètres fixés**. Le rapport de LG (8) devient $\big(e_i^{(\delta_j)}\big)^2/s_i^{2(\delta_j)} = z^2_{j,i}$.

C'est le carré de l'erreur LOO normalisée de la seule correction j (« la part de l'erreur expliquée par le biais δ^j », dans les mots de LG), qu'on lit dans `gps[j-1]` sans réajuster.

5 D'où vient l'équation (N5)

Un calcul de plus, une mise à jour de rang un. Pour deux variables conjointement gaussiennes (A, W), on a $\mathrm{Var}(A|W) = \mathrm{Var}\,A - \mathrm{Cov}(A,W)^2/\mathrm{Var}\,W$, et ce résultat *ne dépend pas de la valeur* de W. Calculer $\boldsymbol{x}_0$ aux niveaux $1..l$ fournit les résidus $d_1(\boldsymbol{x}_0), \dots, d_l(\boldsymbol{x}_0)$, puisque $z_{j-1}(\boldsymbol{x}_0)$ est connu pour former $d_j(\boldsymbol{x}_0)$. Les niveaux $j > l$ ne reçoivent rien. Pour $j \le l$, on prend, sous la loi a posteriori courante, $A = \delta_j(\boldsymbol{x})$ et $W = d_j(\boldsymbol{x}_0) = \delta_j(\boldsymbol{x}_0) + \varepsilon_j$: $\mathrm{Cov}(A,W) = k_j^n(\boldsymbol{x}, \boldsymbol{x}_0)$ et $\mathrm{Var}\,W = \sigma_j^2(\boldsymbol{x}_0) + \tau_j^2$. D'où

$$\sigma_j^2(\boldsymbol{x}) \;\longrightarrow\; \sigma_j^2(\boldsymbol{x}) - \frac{k_j^n(\boldsymbol{x}, \boldsymbol{x}_0)^2}{\sigma_j^2(\boldsymbol{x}_0) + \tau_j^2}.$$

Retour à la sortie HF. Le nouveau plan est encore imbriqué. Le §3 s'applique avant et après l'ajout, et la différence des deux variances vaut

$$\Delta\,\mathrm{Var}[Z_L(\boldsymbol{x})] = \sum_{j=1}^{l} P_j^2\, \frac{k_j^n(\boldsymbol{x}, \boldsymbol{x}_0)^2}{\sigma_j^2(\boldsymbol{x}_0) + \tau_j^2}, \qquad G_l(\boldsymbol{x}_0) = \int_{\mathcal{Q}} \Delta\,\mathrm{Var}[Z_L(\boldsymbol{x})]\, d\boldsymbol{x}.$$

L'intégrale est estimée par la moyenne sur N points de Sobol du cube unité, ce qui donne (N5). Le facteur $a_j(\boldsymbol{x}_0)$ de (N5) est l'ajustement heuristique de LG (10), ajouté par-dessus ce résultat exact.

Lecture physique. On note $c_j(\boldsymbol{x}, \boldsymbol{x}_0) = k_j^n(\boldsymbol{x}, \boldsymbol{x}_0)/(\sigma_j(\boldsymbol{x})\sigma_j(\boldsymbol{x}_0))$ la corrélation a posteriori. Alors

$$\frac{k_j^n(\boldsymbol{x}, \boldsymbol{x}_0)^2}{\sigma_j^2(\boldsymbol{x}_0) + \tau_j^2} = \underbrace{\sigma_j^2(\boldsymbol{x})}_{\text{ignorance en } \boldsymbol{x}} \times \underbrace{c_j(\boldsymbol{x}, \boldsymbol{x}_0)^2}_{\text{lien entre } \boldsymbol{x} \text{ et } \boldsymbol{x}_0} \times \underbrace{\frac{\sigma_j^2(\boldsymbol{x}_0)}{\sigma_j^2(\boldsymbol{x}_0) + \tau_j^2}}_{\text{part non bruitée du calcul}}.$$

Lien avec le proxy LG (5). Supposons $k_j^n(\boldsymbol{x}, \boldsymbol{x}_0) \approx \sigma_j^2(\boldsymbol{x}_0)\, r_j(\boldsymbol{x} - \boldsymbol{x}_0)$: la covariance garde la forme de la corrélation a priori, ce qui vaut pour un point loin des autres, sans bruit et dans un domaine infini. On a alors $\int k_j^n(\boldsymbol{x}, \boldsymbol{x}_0)^2\, d\boldsymbol{x}/\sigma_j^2(\boldsymbol{x}_0) \approx \sigma_j^2(\boldsymbol{x}_0) \int r_j^2 = \pi^{d/2}\, \sigma_j^2(\boldsymbol{x}_0) \prod_m \theta_{j,m}$, pour le noyau exponentiel carré de mfego. On retrouve $\sigma_{\delta^j}^2(\boldsymbol{x}_0) \prod_m \theta_j^m$, au facteur $\pi^{d/2}$ près, commun à tous les niveaux. Le proxy se dégrade dans trois cas :

— un voisin proche « masque » une partie du volume ;
— $\theta > 1$, alors que le domaine est borné ;
— il y a du bruit.

6 Pourquoi un facteur ρ^2 : la correction de la règle de LG

Quelle IMSE réduit $\mathrm{IMSE}_{\mathrm{red}}^l$ **?** Dans LG (5), les poids s'arrêtent à $l-1$: $\prod_{k=j}^{l-1} \hat{\sigma}_{\rho_k}^2$. Comparé à LG (4), c'est la réduction de l'IMSE de la sortie *du niveau* l, $\int k_{n_l}^l$, et non de la sortie HF. L'objectif est pourtant l'IMSE de Y^s. Calculer $\boldsymbol{x}_0$ jusqu'au niveau l réduit les $\sigma_{\delta^j}^2$ pour $j \le l$, et chacun pèse $\prod_{k=j}^{s-1} \hat{\sigma}_{\rho_k}^2$ dans k^s :

$$\Delta\mathrm{IMSE}^s(\text{jusqu'à } l) = \sum_{j \le l} \Delta\bar{\sigma}_{\delta^j}^2 \prod_{k=j}^{s-1} \hat{\sigma}_{\rho_k}^2 = W_l\, \mathrm{IMSE}_{\mathrm{red}}^l, \qquad W_l = \prod_{k=l}^{s-1} \hat{\sigma}_{\rho_k}^2.$$

La comparaison cohérente. LG lancent le niveau $l-1$ plutôt que l si $B_{l/l-1}\, \mathrm{IMSE}_{\mathrm{red}}^{l-1} > \mathrm{IMSE}_{\mathrm{red}}^l$. En unités HF, il faut comparer $B\, W_{l-1}\, \mathrm{IMSE}_{\mathrm{red}}^{l-1}$ à $W_l\, \mathrm{IMSE}_{\mathrm{red}}^l$. Or $W_{l-1} = \hat{\sigma}_{\rho_{l-1}}^2 W_l$, donc après simplification par W_l :

$$\boxed{B_{l/l-1}\, \hat{\sigma}_{\rho_{l-1}}^2\, \mathrm{IMSE}_{\mathrm{red}}^{l-1} > \mathrm{IMSE}_{\mathrm{red}}^l} \qquad \text{au lieu de} \qquad B_{l/l-1}\, \mathrm{IMSE}_{\mathrm{red}}^{l-1} > \mathrm{IMSE}_{\mathrm{red}}^l.$$

Deux niveaux, explicitement. On note $R_1 = \sigma_{\delta^1}^2 V_1$ et $V_j = \prod_m \theta_j^m$; alors $\mathrm{IMSE}_{\mathrm{red}}^1 = R_1$ et $\mathrm{IMSE}_{\mathrm{red}}^2 = \rho^2 R_1 + \sigma_{\delta^2}^2 V_2$. La BF est lancée si

LG :	$(B - \rho^2)\, R_1 > \sigma_{\delta^2}^2 V_2$,
corrigé, coût d'un seul calcul :	$(B-1)\, \rho^2 R_1 > \sigma_{\delta^2}^2 V_2$,
(N6), coût cumulé :	$B\, \rho^2 R_1 > \sigma_{\delta^2}^2 V_2$.

La dernière forme vient de $\rho^2 R_1/c_1 > (\rho^2 R_1 + \sigma_{\delta^2}^2 V_2)/(c_1 + c_2)$. Les deux corrections ne diffèrent que par la façon de compter le coût d'un calcul HF, qui oblige aussi à faire le calcul BF au même point.

À retenir — trois arguments pour la version corrigée

1. **Homogénéité.** R_1 s'exprime en $[y^1]^2 \cdot [\boldsymbol{x}]^d$ et $\sigma^2_{\delta^2} V_2$ en $[y^2]^2 \cdot [\boldsymbol{x}]^d$. Comme ρ s'exprime en $[y^2]/[y^1]$, seul $\rho^2 R_1$ est homogène au membre de droite. LG comparent des quantités de dimensions différentes.
2. **Invariance.** Changeons l'unité du code BF : $z_1 \to a\, z_1$. Le *même* modèle se réécrit exactement avec $\rho \to \rho/a$ et $\sigma^2_{\delta^1} \to a^2 \sigma^2_{\delta^1}$, et les prédictions HF sont inchangées : la décision ne devrait pas changer non plus.
   — Avec la règle de LG, $a^2 B R_1 > \rho^2 R_1 + \sigma^2_{\delta^2} V_2$: la décision dépend de a. Une BF exprimée en Pa avec une HF en MPa ($a = 10^6$) conduirait à toujours lancer la BF.
   — Avec la règle corrigée, $B\rho^2 R_1$ est invariant.
3. **Sens de variation.** Un ρ grand signifie que la HF est très sensible à la BF : l'incertitude BF est amplifiée par ρ^2, selon la propagation $\mathrm{Var}(\rho X) = \rho^2 \,\mathrm{Var}\, X$. La BF devrait donc devenir *plus* intéressante. Chez LG, le facteur $(B - \rho^2)$ *diminue*, et la BF n'est plus jamais lancée dès que $\rho^2 \geq B$. Exemple : $\hat{\rho} = 2{,}4$, valeur trouvée dans mfego sur Hartmann, avec $B = 5$, donne $5 - 5{,}76 < 0$.

L'exemple de LG ne pouvait pas le montrer : les deux codes calculent la même contrainte de von Mises en MPa, donc $\rho \approx 1$, et les deux règles coïncident presque. Les deux autres corrections de la note s'ajoutent à celle-ci : le gain exact (§ 5) au lieu du volume V_j, et le coût cumulé C_l au lieu du rapport t_l/t_{l-1}.

7 Pourquoi le premier test de l'algorithme 1 devient inutile

Ce qu'il fait. Ligne 3 : si $\sigma^2_{\delta^l}(\boldsymbol{x}_{\text{new}}) < \bar{\sigma}^2_{\delta^l}$, on ne lance pas le niveau l. Ici $\bar{\sigma}^2 = \int_{\mathcal{Q}} \sigma^2_{\delta^l}\, d\boldsymbol{x}$ est une *intégrale*, égale à la moyenne seulement si $|\mathcal{Q}| = 1$. L'idée : si la correction l est mieux connue en $\boldsymbol{x}_{\text{new}}$ qu'en moyenne, le code l y apporte peu. C'est un seuil arbitraire, qui ignore le coût, ρ, le bruit et l'étendue spatiale du gain.

Ce que fait (N6) à sa place. On note $g_l = G_l - G_{l-1}$ le gain *marginal* du niveau l et $c_l = C_l - C_{l-1}$ son coût marginal. Alors

$$\frac{G_l}{C_l} < \frac{G_{l-1}}{C_{l-1}} \iff (G_{l-1} + g_l)\, C_{l-1} < G_{l-1}\, (C_{l-1} + c_l) \iff \boxed{\frac{g_l}{G_{l-1}} < \frac{c_l}{C_{l-1}}}.$$

Le niveau l n'est retenu que si *le gain qu'il ajoute, rapporté au gain déjà obtenu, dépasse le surcoût qu'il impose, rapporté au coût déjà engagé.* C'est la version quantitative du test de LG. Le seuil n'est plus « la moyenne », il est fixé par les coûts.

Pourquoi g_l est petit dans le cas visé par LG. L'inégalité de Cauchy–Schwarz sur la covariance a posteriori, $k^n_l(\boldsymbol{x}, \boldsymbol{x}_0)^2 \leq \sigma^2_l(\boldsymbol{x})\, \sigma^2_l(\boldsymbol{x}_0)$, donne

$$g_l \leq P_l^2\, a_l(\boldsymbol{x}_0)\, \frac{\sigma^2_l(\boldsymbol{x}_0)}{\sigma^2_l(\boldsymbol{x}_0) + \tau^2_l} \int_{\mathcal{Q}} \sigma^2_l(\boldsymbol{x})\, d\boldsymbol{x}.$$

Si la correction l est connue en $\boldsymbol{x}_0$ à mieux que le bruit ($\sigma^2_l(\boldsymbol{x}_0) \ll \tau^2_l$), le niveau l n'apporte presque rien. C'est l'intuition de LG, avec le bon seuil : le bruit, pas la moyenne spatiale. Sans bruit, un point très proche d'un point existant peut encore apporter une information de type gradient ; le gain exact le mesure, alors que le test de LG le refuserait. Enfin, (N6) compare tous les niveaux d'un coup, par un arg max. L'hypothèse de monotonie de l'efficacité, qui justifie chez LG la boucle par paires successives (remarque du § 3.1), n'est plus nécessaire.

Références

[1] L. Le Gratiet, C. Cannamela, *Cokriging-based sequential design strategies using fast cross-validation techniques for multi-fidelity computer codes*, Technometrics 57(3) :418–427, 2015.

[2] L. Le Gratiet, J. Garnier, *Recursive co-kriging model for design of computer experiments with multiple levels of fidelity*, Int. J. Uncertainty Quantification 4(5) :365–386, 2014.

[3] L. Le Gratiet, *Multi-fidelity Gaussian process regression for computer experiments*, thèse, Université Paris Diderot, 2013.

[4] M. C. Kennedy, A. O'Hagan, *Predicting the output from a complex computer code when fast approximations are available*, Biometrika 87(1) :1–13, 2000.

[5] O. Dubrule, *Cross validation of kriging in a unique neighborhood*, Mathematical Geology 15(6) :687–699, 1983.

[6] C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006 (§ 2.7, § 5.4.2, annexe A.2 pour le conditionnement gaussien).