Choisir les nouveaux calculs quand l'objectif est la vitesse VPP

Comment le plan séquentiel de Le Gratiet & Cannamela a été adapté au cas du C-foil

Note pédagogique · `vpp_acceleration` · 23/10/2026, mise à jour le 26/10/2026 (code du 4e run)

Ce que cette note explique. À chaque pas, l'algorithme doit répondre à deux questions : *où* lancer un calcul de code, et *à quel niveau* (BF : NPLLT × NeuralFoil, ou HF : NPLLT × XFOIL). On part de la stratégie de Le Gratiet & Cannamela [1], que tu connais. On montre ce qu'il a fallu changer parce que la question n'est plus « un bon modèle partout », mais « la bonne vitesse là où la VPP travaille », et l'on écrit **chaque hypothèse** faite en chemin (récapitulées au § 7). Le modèle lui-même est le co-krigeage AR(1) imbriqué du document mfego (chapitres 5 et 6), utilisé tel quel, une fois par coefficient du torseur.

1 Le point de départ : la stratégie de Le Gratiet & Cannamela

Ce que disent les références — [1], §3 et algorithme 1

Le but est un modèle du niveau haut Z_2 précis **sur tout le domaine** Q. L'erreur visée est l'IMSE, $\int_Q \mathrm{Var}[Z_2(\boldsymbol{x}) \mid \text{données}]\, d\boldsymbol{x}$. Chaque pas se fait en deux temps :

1. **Où :** au maximum d'une variance de prédiction « ajustée » par validation croisée (leave-one-out), dans la cellule de Voronoï des points existants. C'est un critère de type **ALM** (« active learning MacKay » [4]) : on calcule là où le modèle est le plus incertain ;
2. **Jusqu'à quel niveau :** en comparant, pour ce point, la réduction d'IMSE de chaque niveau rapportée au rapport des coûts. Calculer au niveau 2 impose de calculer aussi le niveau 1 : le plan reste imbriqué.

L'idée de fond, que nous gardons, est celle des stratégies de réduction d'incertitude (SUR [7]) : **on sait, avant de lancer un calcul, combien il réduira la variance du modèle**. La variance d'un GP ne dépend que des positions des observations, et non des valeurs que le code rendra.

Théorie — le gain exact d'un calcul

Ajouter le point $\boldsymbol{x}_m$ au niveau l, c'est observer $\boldsymbol{x}_m$ à tous les niveaux $j \le l$ qui y manquent. Notons :

— $\boldsymbol{c}(\boldsymbol{x})$: la covariance a posteriori entre $Z_2(\boldsymbol{x})$ et ces nouvelles observations ;

— S : la covariance a posteriori de ces observations, bruit compris.

La variance de $Z_2(\boldsymbol{x})$ baisse alors exactement de $\boldsymbol{c}(\boldsymbol{x})^{\mathsf{T}} S^{-1} \boldsymbol{c}(\boldsymbol{x})$. Le gain intégré est

$$G(\boldsymbol{x}_m, l) = \int \boldsymbol{c}(\boldsymbol{x})^{\mathsf{T}} S^{-1} \boldsymbol{c}(\boldsymbol{x})\ \mu(d\boldsymbol{x}) \ \approx\ \frac{1}{N} \sum_{i=1}^{N} \boldsymbol{c}(\boldsymbol{x}_i)^{\mathsf{T}} S^{-1} \boldsymbol{c}(\boldsymbol{x}_i), \tag{1}$$

où μ est la *mesure d'intégration* : uniforme sur Q chez [1], et $\{\boldsymbol{x}_i\}$ des points qui l'échantillonnent. C'est le critère **ALC** (« active learning Cohn » [3]) : on calcule là où l'observation fait le plus baisser la variance *ailleurs*, sur les points de référence. La formule est exacte, à hyperparamètres fixés, avec la covariance jointe des deux niveaux. **Notre algorithme est un ALC**, et non un ALM.

Ce que nous avions déjà changé avant la VPP (note du 19/10, études du 21/10) :

— **Un choix conjoint du point et du niveau**, au meilleur rendement $G(\boldsymbol{x}_m, l)/C(\boldsymbol{x}_m, l)$ parmi tous les couples, au lieu du point au maximum de variance (ALM) puis du niveau. Le maximum de variance attirait les points sur les bords et privait la HF de points (Hartmann 6D). Le choix conjoint ALC corrige cela : erreur de 0,69 à 0,71, contre 0,82 pour un LHS.

— **Le gain de chaque niveau mesuré sur la sortie HF.** La règle publiée compare une réduction BF à une réduction HF, et il lui manque un facteur ρ^2.

— **Ni ajustement par validation croisée** (nos sorties sont lisses), **ni ρ libre** : un prior $\mathcal{N}(1, 2^2)$ le borne (la version « v2 »). Sans ce prior, ρ montait jusqu'à 30.

2 Ce que la VPP change dans la question

Nous ne voulons pas un torseur juste *partout* : nous voulons savoir **quelle section fait aller le bateau le plus vite**. Trois différences en découlent.

1. **La grandeur d'intérêt est la vitesse** V, et non les 7 coefficients. Une erreur sur la traînée et une erreur de même taille sur un moment n'ont pas le même effet sur V.
2. **La VPP n'interroge le foil qu'autour de l'équilibre.** Pour une section donnée, à chaque condition de vent, la VPP cherche une attitude d'équilibre $\boldsymbol{a} = (\text{cant}, \text{rake}, \text{yaw})$. Elle n'évalue le foil qu'au voisinage de cette attitude. Le reste du domaine (13 dimensions : 10 scores de section et 3 angles) lui est inutile.
3. **Les sections qui comptent changent pendant la recherche.** Ce sont le titulaire (la meilleure section du moment) et ses concurrentes.

Chaque différence donne une adaptation du critère (1), présentée dans les trois sections suivantes.

3 Première adaptation : pondérer les sorties par leur effet sur la vitesse

Théorie — de l'erreur sur le torseur à l'erreur sur la vitesse

À un état d'équilibre, une petite erreur δC_k sur le coefficient k change la vitesse d'équilibre de $d_k\,\delta C_k$ environ, où $d_k = \partial V/\partial C_k$ (**hypothèse H4** : premier ordre). Les 7 co-krigeages sont indépendants (**H5**). La variance de la vitesse prédite est donc

$$\operatorname{Var} V \;\approx\; \sum_{k=1}^{6} d_k^2\, s_k^2(\boldsymbol{x}), \tag{2}$$

avec s_k^2 la variance a posteriori du co-krigeage k. Cpmin n'agit pas sur la vitesse : son poids est nul.

Pourquoi c'est indispensable. Voici les vrais chiffres du 3e run, à la meilleure section, condition 45°/16 nd (vitesse 18,57 nd) :

	μ_k	d_k [nd/unité]	s_k [10^{-4}]	$s_k/\lvert\mu_k\rvert$ [%]	$\lvert d_k\rvert\, s_k$ [10^{-3} nd]	part de Var V [%]
F_x	-0,0130	111,0	0,36	0,276	3,97	95,4
F_y	-0,3145	-0,5	0,87	0,028	0,04	0,0
F_z	0,2186	6,9	0,67	0,030	0,46	1,3
M_x	-0,5713	4,8	1,54	0,027	0,74	3,3
M_y	0,0819	0,6	0,62	0,076	0,04	0,0
M_z	0,0770	0,0	0,38	0,050	0,00	0,0

— **La traînée F_x fait 95 % de l'incertitude de vitesse.** Ce n'est pourtant pas le coefficient le plus incertain en valeur absolue : M_x et F_y le sont davantage.

— **La raison est physique.** Si le surrogate surestime un peu l'effort latéral F_y, la VPP retrouve l'équilibre avec une dérive à peine différente, et la vitesse ne bouge presque pas ($d_{F_y} \approx -0{,}5$). Une erreur de traînée, elle, se paie directement en vitesse ($d_{F_x} \approx 111$: 1 % d'erreur sur F_x vaut environ 0,014 nd).

— **La conséquence.** Un critère non pondéré aurait dépensé des calculs à apprendre M_x. Le critère pondéré les dépense sur la traînée.

Dans le code

— Les d_{kc} (coefficient k, condition c) sont calculés par **différences finies avec la VPP complète**, au titulaire : on décale la sortie k du surrogate d'environ 3 % et l'on refait le solve. Cela fait 6 solves décalés par condition, chacun avec son solve de base dans le même processus, refaits une mise à jour sur trois.

— **Les conditions ont une probabilité** w_c ($\sum_c w_c = 1$). Ce sont les 5 conditions du run, de

même poids, ou les nœuds d'une distribution d'usage (option `--search-profile`). Au 4e run, il y a 18 nœuds : 9 au près, 9 au portant, tous de poids 1/18. La probabilité y est portée par la *position* des nœuds, resserrés là où le bateau navigue le plus.

— **Chaque point de contrôle $\boldsymbol{x}_i$ a son poids** (**H6**). Avec $c(i)$ la condition de son état et $n_{s(i)}$ le nombre de points de cet état :

$$\omega_{ik} = \frac{w_{c(i)}\, d^2_{k\,c(i)}}{n_{s(i)}}, \qquad G(\boldsymbol{x}_m, l) = \sum_{k\le 6} \sum_{i=1}^{N} \omega_{ik}\, \boldsymbol{c}_k(\boldsymbol{x}_i)^{\mathsf{T}} S_k^{-1} \boldsymbol{c}_k(\boldsymbol{x}_i). \tag{3}$$

La moyenne $\frac{1}{N}\sum_i$ de l'éq. (1) devient cette somme pondérée. Chaque état compte pour la probabilité de sa condition, quel que soit le nombre de ses points. G est la baisse attendue de la variance de la vitesse, en nd².

Subtilité — ce que ces hypothèses négligent

— **H5** ignore que les erreurs de F_y et de M_x sont liées physiquement : un même défaut de portance les produit toutes les deux.

— **H6** prend les sensibilités *du titulaire*, et les applique aussi aux états des concurrentes à la même condition. Une condition sans équilibre a $d = 0$: elle ne pèse rien. Au 3e run, avant le poids par point (23/10), toutes les conditions pesaient pareil alors que d_{F_x} allait de 84 (45°/12 nd) à 302 (90°/14 nd).

— **H4** vaut tant que les erreurs restent petites devant ce qui déplace l'équilibre.

4 Deuxième adaptation : intégrer là où la VPP travaille

Dans (1), seule la mesure μ change : au lieu du domaine entier, on intègre **autour des états d'équilibre** des sections en compétition (**H7**).

— **Les états :** à chaque mise à jour, 4 sections (le titulaire et ses 3 meilleures concurrentes) aux conditions où la VPP trouve un équilibre. Cela fait 20 états au 3e run (5 conditions), et jusqu'à 72 au 4e (18 nœuds).

— **Les nuages :** 16 points autour de chaque état, l'attitude variant de ±1° en cant, ±0,3° en rake et ±1° en yaw. Un nuage plutôt que l'état seul, parce que l'équilibre se déplace quand le surrogate change : entre deux sections proches, de quelques dixièmes de degré.

— **La section bouge aussi, sur un point sur deux** (recherche locale, 4e run) : $\boldsymbol{z}_s + R\,\boldsymbol{g}/\sqrt{10}$, $\boldsymbol{g} \sim \mathcal{N}(0, I)$, avec R le rayon de la région de confiance (encadré ci-dessous). Les points hors de la famille sont retirés. Une moitié du nuage sert la compétition entre les sections des états, l'autre leur voisinage.

Ce que montre la figure 1.

— **Le critère global** choisit un calcul HF en $x = 0{,}33$, là où le modèle est le plus incertain *en moyenne*.

— **Le critère ciblé** choisit un calcul HF en $x = 0{,}83$, sur un point BF déjà calculé : la HF n'y coûte que 2.

— **Mesuré au voisinage de l'état,** le choix global ne retire que 9 % de la variance que retire le choix ciblé. Le choix ciblé, à lui seul, retire 81 % de la variance locale.

C'est exactement l'effet recherché : chaque calcul sert la décision de la VPP. Sur un test de région (profil 4D, 20 graines), cette intégration ciblée a réduit l'erreur dans la région de 27 % par rapport à un LHS imbriqué.

Théorie — comment les nuages suivent la recherche

Ce n'est plus de la planification d'expériences pure : le critère est couplé à l'optimiseur. À chaque mise à jour :

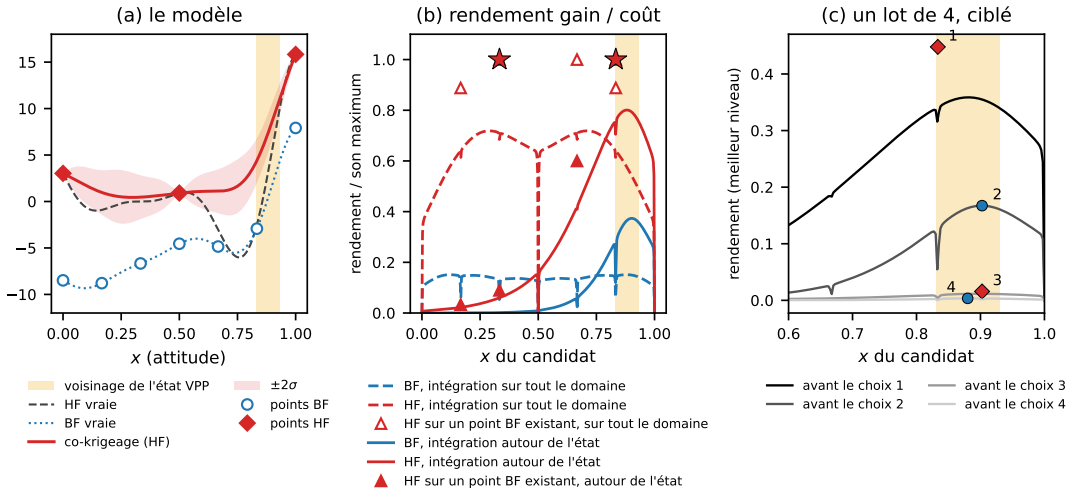


Figure 1 – Exemple 1D à deux niveaux, calculé avec le code du dépôt : Forrester, BF à 7 points, HF à 3 points imbriqués, $\hat{\rho} = 0{,}94$, coûts 1 et 2. La bande jaune est le voisinage d'un « état VPP ». **(a)** Le co-krigeage HF et ses $\pm 2\sigma$. **(b)** Le rendement de chaque candidat et niveau : intégration sur tout le domaine (pointillés, la cible de [1]) ou autour de l'état (traits pleins). Les étoiles marquent les deux choix. **(c)** Le rendement ciblé avant chacun des 4 choix d'un lot (§ 6) : losanges HF, ronds BF.

1. **On crible 256 sections** avec le surrogate : la moitié dans la région de confiance autour du titulaire $\boldsymbol{z}_0$ ($\boldsymbol{z}_0 + R\,\boldsymbol{g}/\sqrt{10}$), l'autre dans toute la famille, avec une graine propre au run. Chaque section reçoit un gain de vitesse au premier ordre, à l'attitude $\boldsymbol{a}_c$ des états du titulaire, avec les moyennes m_k du co-krigeage (**H11**) :

$$\mu(\boldsymbol{z}) = \frac{\sum_c w_c \sum_k d_{kc}\,[m_k(\boldsymbol{z},\boldsymbol{a}_c) - m_k(\boldsymbol{z}_0,\boldsymbol{a}_c)]}{\sum_c w_c}, \qquad \sigma^2(\boldsymbol{z}) = \frac{\sum_c w_c^2 \sum_k d_{kc}^2\, s_k^2(\boldsymbol{z},\boldsymbol{a}_c)}{(\sum_c w_c)^2}.$$

   On garde les 3 meilleurs scores $\mu + \kappa\sigma$, avec $\kappa = 1$. C'est un optimisme face à l'incertitude, comme le critère UCB [9].
2. **Les 3 meilleures passent à la VPP complète,** avec le titulaire. La meilleure vitesse moyenne pondérée, $\sum_c w_c V_c / \sum_c w_c$ sur les conditions résolues pour les 4, donne le titulaire.
3. **La région de confiance s'adapte :** $R \leftarrow \min(3;\ 1{,}5R)$ si le titulaire change en gagnant au moins 0,002 nd, $R \leftarrow \max(0{,}1;\ 0{,}7R)$ sinon (**H12** ; Conn et al. [5], TuRBO [6]).
4. **Les états de ces 4 sections deviennent les nouveaux points d'intégration.**

Depuis le 27/10 (**H13**), une région dont les 10 dernières mises à jour ont gagné moins de 0,01 nd a convergé : on garde son optimum, et une nouvelle région part à au moins 2 de tous les optima. Une section mal connue mais prometteuse entre donc dans le trio, attire des calculs, puis gagne ou est écartée. C'est le mécanisme d'exploration. Le reste du domaine n'est raffiné que par corrélation : sa précision globale n'est pas recherchée (le revers de H7).

Subtilité — w_c dans le critère, w_c^2 dans le criblage

— **Le critère** (3) réduit $\sum_c w_c \operatorname{Var} V_c$, une moyenne des variances : on veut connaître chaque condition probable.

— **Le criblage** prend la variance de la *moyenne* pondérée, en supposant les erreurs indépendantes d'une condition à l'autre. Elles sont en fait corrélées, et ce σ est trop petit. L'exploration est donc un peu plus timide que $\kappa = 1$ ne le laisse croire.

5 Troisième adaptation : le choix du point, du niveau et le coût

Le choix final est un maximum de rendement sur un ensemble *fini* de candidats (**H10**) :

$$(\boldsymbol{x}^\star, l^\star) = \arg\max_{m,\,l} \frac{G(\boldsymbol{x}_m, l)}{C(\boldsymbol{x}_m, l)}, \qquad C(\boldsymbol{x}_m, l) = \sum_{j \le l,\ j \text{ manquant en } \boldsymbol{x}_m} c_j, \tag{4}$$

avec G la somme pondérée (3).

Les candidats sont d'autres points des nuages, tirés comme les points de contrôle avec une autre graine : $\lfloor 512/N_{\text{états}} \rfloor$ par état, soit 25 au 3e run et 7 au 4e. Les points de contrôle mesurent la variance, et les candidats sont les points où l'on *peut* calculer. Jusqu'au 23/10, on y ajoutait 256 points de tout le domaine et les anciens points BF sans HF. Au 3e run, aucun choix n'est allé loin des états, et 2 HF sur 252 seulement sont tombées sur un ancien point BF : ces deux sortes de candidats ont été retirées.

Le coût cumulé vient de l'imbrication (**H2**). Un point nouveau au niveau 2 coûte $c_1 + c_2 = 3$, une HF sur un point BF existant coûte $c_2 = 2$. La figure 1 le montre : le critère ciblé préfère une HF sur un point BF voisin de l'état plutôt qu'un point neuf. Dans la boucle, ce cas ne se présente plus qu'à l'intérieur d'un lot, quand un candidat déjà pris en BF est repris en HF (§ 6).

Le rapport des coûts est de 1 : 2 (**H8**). C'est celui du temps réel par choix, et non celui des temps de calcul des codes. Les calculs d'un lot tournent en parallèle, et un choix coûte surtout le temps de sélection, à peu près le même aux deux niveaux. Une HF n'allonge le lot que si sa section est nouvelle (la polaire XFOIL, de 2 à 13 s). Au 2e run, en séquentiel avec AVL en HF, le rapport valait 1 : 6.

6 Seize calculs à la fois : le « kriging believer »

On ne prend pas simplement les 16 meilleurs rendements de (4) : ce seraient 16 voisins du même maximum, presque redondants. On choisit plutôt l'un après l'autre. Après chaque choix, on conditionne le co-krigeage sur le point choisi *comme s'il avait été calculé*, avec pour valeur provisoire sa moyenne prédite (Ginsbourger et al. [8]).

Pourquoi c'est exact pour notre critère. Le gain (1) ne dépend que de la variance a posteriori. La formule $k_n(\boldsymbol{a}, \boldsymbol{b}) = k(\boldsymbol{a}, \boldsymbol{b}) - \boldsymbol{k}(\boldsymbol{a}, X)K^{-1}\boldsymbol{k}(X, \boldsymbol{b})$ ne contient pas les valeurs observées. Le choix suivant voit donc exactement la variance que les choix précédents vont retirer. La valeur provisoire, elle, laisse les moyennes inchangées : elle ne sert qu'à faire tourner le code, et elle est remplacée par la vraie valeur après le calcul. Depuis le 27/10, on prolonge le facteur de Cholesky au lieu de tout refactoriser : même lot, 97 s au lieu de 269 s.

Sur la figure 1(c), le lot ciblé de 4 donne 0,83 (HF), 0,90 (BF), 0,90 (HF), 0,88 (BF).

— Après les deux premiers choix, le rendement au voisinage de l'état s'effondre, de 0,36 à 0,02 : il est appris.

— Le 3e choix ajoute la HF au point BF que le 2e vient de prendre, ce qui respecte l'imbrication.

— Dans le vrai problème, avec 20 à 72 états, les choix suivants iraient vers d'autres états.

Subtilité — ce qui reste fixe pendant un lot (H9)

Les hyperparamètres (longueurs de corrélation, ρ) ne changent pas pendant le lot. Ils ne sont réestimés que lorsque le plan a grossi de 25 %, et plus du tout au-delà de 2 500 points (au 4e run, la dernière réestimation s'est faite à 2 098 points). Entre deux réestimations, on conditionne seulement. Le critère se fie donc à des longueurs de corrélation estimées sur un plan un peu plus petit. Le lot dépend aussi des sensibilités d_k et des états de la dernière mise à jour.

7 Les hypothèses, en un tableau

	Hypothèse	Pourquoi	Ce qu'on risque
H1	AR(1) à ρ constant, un co-krigeage indépendant par coefficient, même plan	le modèle de [2], validé sur nos cas ; un calcul donne tout le torseur	une corrélation BF/HF qui varie dans le domaine
H2	plan imbriqué : la HF seulement là où la BF existe	condition du co-krigeage récursif	aucun, sinon le coût cumulé
H3	choix conjoint (point, niveau) par l'ALC exact, sans ajustement LOO	bat le maximum de variance sur Hartmann 6D	suppose des hyperparamètres bien estimés
H4	vitesse linéarisée en δC_k	rend le critère calculable	faux si les erreurs déplacent beaucoup l'équilibre
H5	erreurs des 7 sorties indépendantes	7 GP indépendants	corrélations physiques ignorées (F_y, M_x)

	Hypothèse	Pourquoi	Ce qu'on risque
H6	un poids par point : $w_c\, d_{kc}^2$, sensibilités du titulaire	suit la probabilité et l'effet sur la vitesse	sensibilités des concurrentes un peu différentes
H7	intégration autour des états VPP de 4 sections et de leur voisinage en section	seule zone utile à la décision	le reste du domaine peu appris
H8	coûts 1 : 2 en temps réel par choix	calculs parallèles	mal réglé, il gaspille les HF ou les BF
H9	hyperparamètres et sensibilités figés pendant un lot	le gain doit être calculable sans relancer les codes	un lot de 16 un peu moins bien placé
H10	maximum sur un ensemble fini de candidats	le calcul vectorisé du gain	un meilleur point entre les candidats
H11	criblage au premier ordre, à l'attitude du titulaire, erreurs indépendantes entre conditions	trier 256 sections sans 256 VPP	σ optimiste ; une bonne section mal classée
H12	région de confiance : $\times 1{,}5$ si le gain $\geq 0{,}002$ nd, $\times 0{,}7$ sinon, $R \in [0{,}1; 3]$	resserrer quand le titulaire tient	un optimum local si R se resserre trop tôt
H13	convergence d'une région (10 mises à jour, 0,01 nd) puis redémarrage à distance ≥ 2	ne pas raffiner un optimum acquis ; chercher un autre bassin	un départ mal jugé au premier ordre coûte une région

8 Le cœur et les ajouts

Tu as raison : le code est devenu plus compliqué que ce que nous avions convenu. Pour le comprendre, il suffit de garder le **cœur**, qui tient en quatre lignes :

1. le co-krigeage AR(1) de [2], un par coefficient (H1, H2) ;
2. le gain exact (1) et le choix au meilleur rendement (4) (H3) ;
3. la pondération par $w_c\,(\partial V/\partial C_k)^2$ (H4–H6) ;
4. l'intégration autour des états VPP, qui suivent la recherche (H7, H11, H12).

Le reste sert à aller plus vite, et ne change pas la logique : les lots de 16 (§ 6), les processus parallèles pour les codes et la VPP, les fils sur les 7 modèles, la prédiction « moyenne seule » pour la VPP, la règle des 25 % et le gel à 2 500 points pour les hyperparamètres, et l'exclusion des points en échec. Avec un lot de 1, sans processus parallèles, sans distribution d'usage ni recherche locale, on retrouve l'algorithme du 2e run. Ces couches peuvent se ranger derrière une option, pour que le cœur se lise d'un seul tenant.

Références

[1] L. Le Gratiet, C. Cannamela, *Cokriging-based sequential design strategies using fast cross-validation techniques for multi-fidelity computer codes*, Technometrics 57(3), 418–427, 2015.

[2] L. Le Gratiet, *Multi-fidelity Gaussian process regression for computer experiments*, thèse, Université Paris-Diderot, 2013.

[3] D. Cohn, *Neural network exploration using optimal experiment design*, Neural Networks 9(6), 1996.

[4] D. J. C. MacKay, *Information-based objective functions for active data selection*, Neural Computation 4(4), 590–604, 1992.

[5] A. R. Conn, N. I. M. Gould, P. L. Toint, *Trust-Region Methods*, SIAM, 2000.

[6] D. Eriksson, M. Pearce, J. Gardner, R. Turner, M. Poloczek, *Scalable global optimization via local Bayesian optimization*, NeurIPS 2019.

[7] J. Bect, D. Ginsbourger, L. Li, V. Picheny, E. Vazquez, *Sequential design of computer experiments for the estimation of a probability of failure*, Statistics and Computing 22, 2012.

[8] D. Ginsbourger, R. Le Riche, L. Carraro, *Kriging is well-suited to parallelize optimization*, in *Computational Intelligence in Expensive Optimization Problems*, Springer, 2010.

[9] N. Srinivas, A. Krause, S. Kakade, M. Seeger, *Gaussian process optimization in the bandit setting : no regret and experimental design*, ICML 2010.